

Guía de modelos de IA — ¿cuál usar para qué?

Actualizada: octubre 2026. Los modelos cambian seguido: antes de usar uno en producción, verifica el nombre exacto en la documentación oficial del proveedor.

Regla de oro: usa el modelo más barato que haga bien la tarea. Arranca con el económico y sube solo si se queda corto.

Costo relativo: \$ muy barato · \$ \$ medio · \$ \$ \$ caro · \$ \$ \$ \$ premium

Anthropic (Claude) — tu API key actual

Modelo	Nombre en el código (model=)	Costo	Recomendado para
Claude Haiku 4.5	claude-haiku-4-5-20251001	\$	Chatbots de atención al cliente, clasificar textos, respuestas rápidas, tareas repetitivas de alto volumen. Tu punto de partida para practicar.
Claude Sonnet 5.5	claude-sonnet-5-5	\$ \$	El equilibrio: agentes, código, análisis de documentos, extracción de datos de facturas, la mayoría de automatizaciones de negocio.
Claude Opus 5.5	claude-opus-5-5	\$ \$ \$	Razonamiento complejo, análisis delicados donde un error sale caro (ej. conciliaciones críticas), tareas largas de varios pasos.
Claude Fable 5.1	claude-fable-5-1	\$ \$ \$ \$	Gama más alta. Solo para retos muy difíciles; casi nunca necesario para automatizaciones normales.

OpenAI (GPT)

Modelo	Nombre en el código	Costo	Recomendado para
GPT-6 Luna	gpt-6-luna	\$	Tareas de alto volumen y bajo costo, chatbots sencillos.
GPT-6.1 Sol	gpt-6.1-sol	\$ \$	Equilibrio entre inteligencia y costo.
GPT-6 Astra	(ver docs de OpenAI)	\$ \$ \$	Su modelo insignia: razonamiento complejo y código.

Google (Gemini)

Modelo	Nombre en el código	Costo	Recomendado para
Gemini 3.5 Flash-Lite	gemini-3.5-flash-lite	\$	Muy barato y rápido; tareas simples y de alto volumen.
Gemini 3.8 Flash	gemini-3.8-flash	\$ \$	Caballo de batalla: agentes, código, flujos de varios pasos.
Gemini 3.1 Pro	gemini-3.1-pro-preview	\$ \$ \$	Tareas complejas y razonamiento avanzado (aún en preview).

Modelos de código abierto (los descargas y corres tú)

Familia	Creador	Costo	Recomendado para
Llama	Meta	Gratis por token (pagas hardware/servidor)	Datos muy sensibles que no pueden salir de tu infraestructura.
DeepSeek	DeepSeek (China)	Gratis local / API muy barata	Bajo costo. Ojo con la privacidad si usas su API en la nube.
Qwen	Alibaba (China)	Gratis local / API barata	Igual que DeepSeek.

Guía rápida por caso de uso

Si quieres...	Usa
Chatbot de atención al cliente	Haiku / GPT-6 Luna / Gemini Flash-Lite
Resumir, traducir, redactar correos	Haiku o Sonnet
Extraer datos de facturas o documentos	Sonnet
Agente que usa herramientas y toma decisiones	Sonnet (Opus si es muy complejo)
Análisis crítico donde un error cuesta mucho	Opus
Datos confidenciales sin salir de la empresa	Modelo abierto en servidor propio, o Claude vía Bedrock / Vertex / Azure según la nube de la empresa

Recordatorios

- Una sola API key sirve para **todos** los modelos de ese proveedor: el modelo lo eliges en la línea `model=` de tu código.
- Ponle límite de gasto a tu cuenta y deja apagada la recarga automática mientras practicas.
- No amarres tu código a un solo proveedor: así puedes cambiar de modelo según precio y calidad para cada cliente.

Documentación oficial: [Anthropic](#) · [OpenAI](#) · [Google Gemini](#)